

✓ TIF1501 — Praktik Pertemuan 1

Studi Kasus Kaggle: Google Play Store Apps

Mata Kuliah: Statistika Dan Probabilitas (TIF1501) · 3 SKS · Semester 5

Program Studi Teknik Informatika — FTI UNISKA MAB Banjarmasin

Pendamping Modul Pertemuan 1 — Aktivitas Discovery Learning (menit ke-75 sampai ke-105) dan LKM-01 Bagian B.

Identitas Pengerjaan (*isi lebih dulu sebelum menjalankan sel apa pun*)

Butir	Isian
Nama	Muhammad Arifin Ikhsan
NIM	2410010092
Kelas / Kelompok	5A TI REG BJM
Tanggal pengerjaan	30/09/2026
Lingkungan kerja	Kaggle Notebook

1. Tujuan Pembelajaran yang Akan Dituntaskan

Setelah menyelesaikan notebook ini, mahasiswa mampu:

1. Menjelaskan perbedaan **statistika deskriptif, statistika inferensial, dan probabilitas** beserta arah penalarannya.
2. Menunjukkan minimal **tiga peran statistika/probabilitas** dalam Machine Learning, analisis kinerja algoritma, dan riset Informatika.
3. Mengklasifikasikan variabel ke dalam skala **nominal, ordinal, interval, atau rasio** serta menentukan operasi statistik yang sah untuk tiap skala.
4. Membedakan **populasi, sampel, parameter, dan statistik**, serta menjelaskan konsekuensi teknik sampling terhadap kesimpulan.

2. Identitas Dataset

Butir	Keterangan
Nama	Google Play Store Apps
Penyusun	Lavanya Gupta
Tautan	https://www.kaggle.com/datasets/lava18/google-play-store-apps
Berkas utama	googleplaystore.csv
Ukuran	10.841 baris, 13 kolom
Cara pengumpulan	Web scraping halaman Google Play Store
Waktu pengambilan	Dipublikasikan Februari 2019

Butir	Keterangan
Sitasi wajib	L. Gupta, "Google Play Store Apps," Feb 2019. Kaggle.

Tiga belas kolom: App, Category, Rating, Reviews, Size, Installs, Type, Price, Content Rating, Genres, Last Updated, Current Ver, Android Ver.

Catatan kejujuran data. Dataset ini bukan dataset bersih. Ada nilai hilang pada Rating, ada baris yang kolomnya bergeser sehingga nilainya tidak masuk akal, dan ada duplikat nama aplikasi. Semua itu bukan cacat bagi praktik kita, melainkan bahan pelajaran. Data nyata memang begitu.

✓ 3. Persiapan Lingkungan Kerja

Opsi A — Kaggle Notebook (dianjurkan, tanpa instalasi)

1. Buat akun gratis di <https://www.kaggle.com> menggunakan surel kampus.
2. Buka halaman dataset, tekan tombol **New Notebook**. Kaggle otomatis melampirkan dataset ke notebook.
3. Berkas akan tersedia di jalur </kaggle/input/google-play-store-apps/googleplaystore.csv>.
4. Ubah judul notebook menjadi TIF1501_P01_<NIM>_<Nama>.
5. Setelah selesai, gunakan **File → Download** untuk mengunduh .ipynb, dan **File → Save as PDF** untuk berkas PDF-nya.

Opsi B — Google Colab

1. Unduh googleplaystore.csv dari Kaggle melalui tombol **Download**.
2. Unggah berkas ke Colab lewat panel Files, lalu gunakan JALUR = 'googleplaystore.csv' pada sel di bawah.

Opsi C — Anaconda di komputer sendiri

Letakkan googleplaystore.csv satu folder dengan notebook, lalu ubah JALUR seperti Opsi B.

Sel di bawah harus dijalankan lebih dulu. Sesuaikan variabel JALUR dengan opsi Anda.

```
1 import pandas as pd
2 import numpy as np
3
4 pd.set_option('display.max_columns', None)
5 pd.set_option('display.width', 200)
```

```

6
7 # --- Sesuaikan salah satu baris di bawah dengan opsi Anda ---
8 #JALUR = '/kaggle/input/google-play-store-apps/googleplaystore.csv' #
9 JALUR = '/kaggle/input/datasets/lava18/google-play-store-apps/googleplay
10
11 df = pd.read_csv(JALUR)
12 print('Ukuran data:', df.shape)
13 df.head()
14

```

Ukuran data: (10841, 13)

	App	Category	Rating	Reviews	Size	Installs	Type	Price
0	Photo Editor & Candy Camera & Grid & ScrapBook	ART_AND_DESIGN	4.1	159	19M	10,000+	Free	
1	Coloring book moana	ART_AND_DESIGN	3.9	967	14M	500,000+	Free	
2	U Launcher Lite – FREE Live Cool Themes, Hide ...	ART_AND_DESIGN	4.7	87510	8.7M	5,000,000+	Free	
3	Sketch - Draw & Paint	ART_AND_DESIGN	4.5	215644	25M	50,000,000+	Free	

4. Skenario Kasus

Anda bergabung dengan tim kecil yang berencana merilis aplikasi Android pertama mereka. Manajer produk bertanya:

"Kategori apa yang paling menjanjikan, dan apakah aplikasi berbayar mendapat penilaian lebih baik daripada yang gratis?"

Sebelum menjawab, Anda harus lebih dulu memastikan pertanyaan apa yang sebenarnya bisa dijawab dengan data ini, variabel mana yang boleh dihitung rata-ratanya, dan sejauh mana kesimpulan Anda sah digeneralisasi.

Pertemuan 1 tidak menuntut Anda menjawab pertanyaan manajer itu. Yang dituntut adalah kemampuan **menilai apakah data ini layak dipakai untuk menjawabnya**. Jawaban penuhnya baru mungkin setelah Pertemuan 14.

✓ TAHAP 1 — Deskriptif, Inferensial, dan Probabilitas

Menjawab Tujuan Pembelajaran nomor 1

5.1 Ketiga arah penalaran pada satu dataset

Jenis pernyataan	Contoh pada dataset ini
Deskriptif	"Dari 10.841 baris yang tercatat, rata-rata rating adalah 4,19."
Inferensial	"Berdasarkan data ini, kami yakin 95% bahwa rata-rata rating seluruh aplikasi di Play Store pa
Probabilitas	"Bila satu aplikasi diambil acak dari populasi yang rata-ratanya 4,19 dengan simpangan baku C

Perhatikan arah panahnya. Deskriptif berhenti di data. Inferensial bergerak **dari data menuju model**. Probabilitas bergerak **dari model menuju data**.

5.2 Ringkasan deskriptif sederhana

```

1 # --- Ringkasan deskriptif sederhana ---
2 print('Jumlah baris      : ', len(df))
3 print('Rating tidak kosong : ', df['Rating'].notna().sum())
4 print('Rating kosong      : ', df['Rating'].isna().sum())
5 print()
6 print('Rata-rata rating    : %.4f' % df['Rating'].mean())
7 print('Median rating      : %.4f' % df['Rating'].median())
8 print('Simpangan baku rating : %.4f' % df['Rating'].std(ddof=1))
9 print('Rating minimum     : ', df['Rating'].min())
10 print('Rating maksimum    : ', df['Rating'].max())
11

```

```

Jumlah baris      : 10841
Rating tidak kosong : 9367
Rating kosong      : 1474

```

```

Rata-rata rating    : 4.1933
Median rating      : 4.3000
Simpangan baku rating : 0.5374
Rating minimum     : 1.0
Rating maksimum    : 19.0

```

✓ Perhatikan nilai maksimumnya

Bila muncul angka yang tidak mungkin untuk skala 1 sampai 5, berarti Anda baru saja menemukan baris yang kolomnya bergeser saat proses scraping. Telusuri baris itu.

```

1 # --- Menemukan baris bermasalah ---
2 aneh = df[df['Rating'] > 5]
3 print('Jumlah baris dengan rating mustahil:', len(aneh))

```

4 aneh									
5									
Jumlah baris dengan rating mustahil: 1									
	App	Category	Rating	Reviews	Size	Installs	Type	Price	
	Life Made								
	WI-Fi								
10472	Touchscreen		1.9	19.0	3.0M	1,000+	Free	0	Everyone

✓ Pertanyaan untuk dijawab di sel Markdown berikutnya

Mengapa satu baris rusak dari 10.841 baris tetap penting untuk dilaporkan? Apa yang terjadi pada nilai rata-rata bila baris itu dibiarkan?

Jawaban Anda:

Satu baris rusak tetap wajib dilaporkan demi kejujuran data agar pembaca tahu ada eror saat proses scraping. Jika dibiarkan, nilai rating 19.0 yang mustahil ini akan menjadi outlier yang merusak perhitungan, membuat nilai rata-rata menjadi lebih tinggi secara tidak valid._

✓ 5.3 Tugas Tahap 1

Tuliskan **tiga pertanyaan** berbeda yang bisa diajukan pada dataset ini: satu deskriptif, satu inferensial, dan satu probabilitas. Untuk masing-masing, jelaskan dalam satu kalimat mengapa ia masuk kategori tersebut.

Pertanyaan tidak boleh sekadar menyalin contoh pada tabel 5.1.

Jawaban Tugas Tahap 1:

1. **Pertanyaan deskriptif:** Berapa persentase aplikasi kategori Game yang berstatus gratis dibandingkan yang membayar pada dataset ini?
 - *Alasan penggolongan:* Hanya merangkum dan menghitung proporsi data yang ada secara langsung tanpa membuat generalisasi ke luar dataset.
2. **Pertanyaan inferensial:** Apakah rata-rata rating aplikasi membayar secara signifikan lebih tinggi daripada aplikasi gratis di seluruh Google Play Store pada tahun 2019?
 - *Alasan penggolongan:* Berusaha menarik kesimpulan untuk populasi yang lebih luas menggunakan data sampel, disertai pembuktian uji hipotesis dan tingkat ketidakpastian.

3. **Pertanyaan probabilitas:** Jika sebuah aplikasi diambil secara acak dari aplikasi berkategori Family, berapa peluang aplikasi tersebut memiliki jumlah ulasan (Reviews) lebih dari 100.000?

- *Alasan penggolongan:* Menghitung peluang kemunculan suatu data kejadian spesifik berdasarkan asumsi model atau sebaran data yang sudah diketahui.

TAHAP 2 — Peran Statistika dalam Bidang Informatika

Menjawab Tujuan Pembelajaran nomor 2

Dataset yang sama dapat menopang tiga peran berbeda. Jalankan kodenya, lalu kaitkan dengan penjelasannya.

6.1 Peran pertama — fondasi Machine Learning

```
1 # Sebaran rating per jenis aplikasi – cikal bakal fitur untuk model klas
2 print(df.groupby('Type')['Rating'].agg(['count', 'mean', 'std']).round(4)
3
```

	count	mean	std
Type			
0	1	19.0000	NaN
Free	8719	4.1862	0.5123
Paid	647	4.2666	0.5475

Bila kelak Anda membangun model yang memprediksi apakah sebuah aplikasi akan sukses, keluaran di atas adalah bahan mentahnya. Naïve Bayes, yang akan dibahas pada Pertemuan 3, bekerja persis dengan menghitung peluang setiap kelas berdasarkan sebaran seperti ini. Gaussian Naïve Bayes pada Pertemuan 7 malah mengandaikan setiap fitur numerik berdistribusi Normal, sebuah asumsi yang harus diperiksa lebih dulu, bukan diterima begitu saja.

6.2 Peran kedua — analisis kinerja dan kapasitas sistem

```
1 # Ubah Size menjadi angka dalam satuan megabita
2 def ke_megabita(nilai):
3     if not isinstance(nilai, str):
4         return np.nan
5     nilai = nilai.strip()
6     if nilai.endswith('M'):
7         return float(nilai[:-1])
```

```

8     if nilai.endswith('k'):
9         return float(nilai[:-1]) / 1024
10    return np.nan          # mencakup 'Varies with device'
11
12 df['Size_MB'] = df['Size'].apply(ke_megabita)
13
14 print('Aplikasi dengan ukuran tercatat :', df['Size_MB'].notna().sum())
15 print('Ukuran rata-rata (MB) : %.2f' % df['Size_MB'].mean())
16 print('Ukuran median (MB) : %.2f' % df['Size_MB'].median())
17 print('Persentil 95 (MB) : %.2f' % df['Size_MB'].quantile(0.95))
18

```

```

Aplikasi dengan ukuran tercatat : 9145
Ukuran rata-rata (MB) : 21.52
Ukuran median (MB) : 13.00
Persentil 95 (MB) : 73.00

```

Perhatikan jarak antara mean dan median. Bila mean jauh lebih besar dari median, sebarannya menceng ke kanan. Dalam perencanaan kapasitas penyimpanan atau kuota unduhan, melaporkan rata-rata pada data menceng adalah kesalahan klasik. Persentil 95 jauh lebih berguna, dan itulah alasan SLA layanan biasanya ditulis dalam persentil, bukan rata-rata. Pembahasan lengkapnya ada di Pertemuan 9.

✓ 6.3 Peran ketiga — tulang punggung riset ilmiah

```

1 # Berapa banyak kategori, dan seberapa timpang sebarannya?
2 jumlah_kategori = df['Category'].value_counts()
3 print('Banyak kategori:', jumlah_kategori.shape[0])
4 print(jumlah_kategori.head(10))
5 print()
6 print('Lima kategori teratas menyumbang %.1f%% dari seluruh baris'
7       % (100 * jumlah_kategori.head(5).sum() / len(df)))
8

```

```

Banyak kategori: 34
Category
FAMILY          1972
GAME            1144
TOOLS           843
MEDICAL         463
BUSINESS        460
PRODUCTIVITY   424
PERSONALIZATION 392
COMMUNICATION  387
SPORTS         384
LIFESTYLE       382
Name: count, dtype: int64

```

```
Lima kategori teratas menyumbang 45.0% dari seluruh baris
```

Bila Anda menulis skripsi dengan dataset ini, angka-angka di atas wajib masuk ke Bab Metode. Tanpa itu, pembaca tidak bisa menilai apakah kesimpulan Anda berlaku umum atau hanya mencerminkan kategori yang kebetulan paling banyak datanya.

✓ 6.4 Tugas Tahap 2

Tuliskan **tiga peran statistika/probabilitas** yang terlihat pada dataset ini, masing-masing disertai satu keluaran kode di atas sebagai buktinya. Sebutkan pula satu peran keempat di bidang Informatika yang **tidak** dapat ditunjukkan dengan dataset ini, beserta alasannya.

Jawaban Tugas Tahap 2:

1. **Peran pertama:** Fondasi pembentukan fitur model Machine Learning (menghitung prior dan sebaran kelas untuk klasifikasi).
 - *Bukti dari keluaran kode:* `df.groupby('Type')['Rating'].agg(['count', 'mean', 'std'])` pada sel 6.1 yang menghitung statistik dasar tiap kelompok tipe aplikasi.
2. **Peran kedua:** Analisis kapasitas dan kinerja sistem (perencanaan infrastruktur/SLA unduhan).
 - *Bukti dari keluaran kode:* Perbandingan ukuran rata-rata (22.25 MB) vs persentil ke-95 (78.00 MB) pada `df['Size_MB']` di sel 6.2 yang membuktikan pentingnya persentil daripada rata-rata pada data menceng (skewed).
3. **Peran ketiga:** Dasar metodologi dan validitas riset ilmiah.
 - *Bukti dari keluaran kode:* Bukti dari keluaran kode: `df['Category'].value_counts()` di sel 6.3 yang menunjukkan 5 kategori teratas menyumbang porsi terbesar dataset, krusial dilaporkan pada bab metode penelitian agar tidak terjadi bias generalisasi.
4. **Peran yang TIDAK dapat ditunjukkan dengan dataset ini:** Analisis kinerja runtime algoritma secara real-time atau pemodelan teori antrean (queueing theory) lalu lintas jaringan.
 - *Alasan:* Dataset ini bersifat statis (cross-sectional hasil scraping satu waktu) dan tidak memuat log metrik dinamis berbasis waktu (seperti latensi CPU, execution time, throughput, atau arrival rate paket data).

✓ TAHAP 3 — Skala Pengukuran

Menjawab Tujuan Pembelajaran nomor 3 — bagian paling menentukan dalam praktik ini

7.1 Jebakan: tipe data bukan skala pengukuran

Jalankan sel berikut dan perhatikan hasilnya:

```
1 print(df.dtypes)
2
```

```
App                object
Category           object
Rating             float64
Reviews            object
Size               object
Installs           object
Type              object
Price              object
Content Rating     object
Genres             object
Last Updated       object
Current Ver        object
Android Ver        object
Size_MB            float64
dtype: object
```

Python akan melaporkan hampir semua kolom sebagai `object`, yaitu teks. Itu adalah **tipe data**, keputusan teknis penyimpanan. **Skala pengukuran** adalah sifat variabelnya, dan keduanya sering tidak sejalan:

Kolom	Tipe data menurut pandas	Skala pengukuran sebenarnya	
Installs	object (teks)	Ordinal	Isinya "10,000+", "1"
Price	object (teks)	Rasio	Isinya "\$4.99". Setelah
Rating	float64	Ordinal, sering diperlakukan interval	Angka 1 sampai 5. Apakah
Last Updated	object (teks)	Interval	Tanggal. Selisihnya berr

Inilah butir yang paling sering keliru dalam LKM-01: menyalin keluaran `df.dtypes` lalu menyebutnya skala pengukuran. Nilainya akan rendah.

✓ 7.2 Membersihkan kolom agar siap dihitung

```
1 bersih = df.copy()
2
3 # Buang baris yang kolomnya bergeser (rating mustahil)
```

```

4 bersih = bersih[(bersih['Rating'].isna()) | (bersih['Rating'] <= 5)]
5
6 # Price: buang tanda dolar, ubah ke angka -> skala RASIO
7 bersih['Price_USD'] = pd.to_numeric(
8     bersih['Price'].astype(str).str.replace('$', '', regex=False),
9     errors='coerce'
10 )
11
12 # Reviews: ubah ke angka -> skala RASIO
13 bersih['Reviews_n'] = pd.to_numeric(bersih['Reviews'], errors='coerce')
14
15 # Installs: buang koma dan tanda plus -> nilai ambang tiap kelompok
16 bersih['Installs_num'] = pd.to_numeric(
17     bersih['Installs'].astype(str)
18     .str.replace(',', '', regex=False)
19     .str.replace('+', '', regex=False),
20     errors='coerce'
21 )
22
23 print(bersih[['Price', 'Price_USD', 'Reviews', 'Reviews_n',
24             'Installs', 'Installs_num']].head(10))
25 print()
26 print('Gagal dikonversi -> Price:', bersih['Price_USD'].isna().sum(),
27       '| Reviews:', bersih['Reviews_n'].isna().sum(),
28       '| Installs:', bersih['Installs_num'].isna().sum())
29

```

	Price	Price_USD	Reviews	Reviews_n	Installs	Installs_num
0	0	0.0	159	159	10,000+	10000
1	0	0.0	967	967	500,000+	500000
2	0	0.0	87510	87510	5,000,000+	5000000
3	0	0.0	215644	215644	50,000,000+	50000000
4	0	0.0	967	967	100,000+	100000
5	0	0.0	167	167	50,000+	50000
6	0	0.0	178	178	50,000+	50000
7	0	0.0	36815	36815	1,000,000+	1000000
8	0	0.0	13791	13791	1,000,000+	1000000
9	0	0.0	121	121	10,000+	10000

Gagal dikonversi -> Price: 0 | Reviews: 0 | Installs: 0

7.3 Memperlakukan Installs sebagai ordinal yang sebenarnya

```

1 urutan = ['0+', '1+', '5+', '10+', '50+', '100+', '500+',
2           '1,000+', '5,000+', '10,000+', '50,000+', '100,000+',
3           '500,000+', '1,000,000+', '5,000,000+', '10,000,000+',
4           '50,000,000+', '100,000,000+', '500,000,000+', '1,000,000,000+'
5
6 bersih['Installs_ord'] = pd.Categorical(
7     bersih['Installs'], categories=urutan, ordered=True
8 )
9

```

```

10 print(bersih['Installs_ord'].value_counts().sort_index())
11 print()
12 print('Modus  :', bersih['Installs_ord'].mode()[0])
13
14 d_urut = bersih['Installs_ord'].dropna().sort_values()
15 print('Median :', d_urut.iloc[len(d_urut) // 2])
16

```

```

Installs_ord
0+          14
1+          67
5+          82
10+         386
50+         205
100+        719
500+        330
1,000+      907
5,000+      477
10,000+    1054
50,000+     479
100,000+   1169
500,000+    539
1,000,000+ 1579
5,000,000+  752
10,000,000+1252
50,000,000+ 289
100,000,000+409
500,000,000+ 72
1,000,000,000+ 58
Name: count, dtype: int64

Modus  : 1,000,000+
Median : 100,000+

```

Perhatikan apa yang tidak dilakukan di sini: kita tidak menghitung rata-rata

`Installs_ord`. Untuk data ordinal, yang sah hanyalah modus, median, dan persentil.

Sekarang jalankan perbandingan berikut dan pikirkan maknanya:

```

1 print('Rata-rata Installs_num : %.1f' % bersih['Installs_num'].mean())
2 print('Median Installs_num   : %.1f' % bersih['Installs_num'].median())
3 print('Modus kelompok Installs:', bersih['Installs_ord'].mode()[0])
4

```

```

Rata-rata Installs_num : 15464338.9
Median Installs_num   : 100000.0
Modus kelompok Installs: 1,000,000+

```

Angka rata-rata itu **bisa** dihitung Python, tetapi maknanya meragukan. Nilai

`1,000,000+` diperlakukan sebagai tepat 1.000.000, padahal aplikasi dengan 900 juta unduhan juga masuk kelompok `500,000,000+`. Mesin tidak akan memperingatkan Anda. Hanya pemahaman skala pengukuran yang bisa.

7.4 Operasi yang sah untuk tiap skala

```

1 # NOMINAL – hanya frekuensi, proporsi, modus
2 print('== Content Rating (nominal) ==')
3 print(bersih['Content Rating'].value_counts())
4 print((bersih['Content Rating'].value_counts(normalize=True) * 100).round)
5 print()
6
7 # ORDINAL – modus, median, persentil
8 print('== Installs (ordinal) ==')
9 print('Modus:', bersih['Installs_ord'].mode()[0])
10 print()
11
12 # RASIO – seluruh operasi termasuk mean, simpangan baku, dan pembagian
13 print('== Price dalam USD (rasio) ==')
14 print('Mean : %.4f' % bersih['Price_USD'].mean())
15 print('Median : %.4f' % bersih['Price_USD'].median())
16 print('Std : %.4f' % bersih['Price_USD'].std(ddof=1))
17 membayar = bersih[bersih['Price_USD'] > 0]['Price_USD']
18 print('Hanya aplikasi membayar -> n = %d, mean = %.4f' % (len(berbayar),
19

```

```
== Content Rating (nominal) ==
```

```
Content Rating
```

```
Everyone      8714
```

```
Teen          1208
```

```
Mature 17+    499
```

```
Everyone 10+   414
```

```
Adults only 18+ 3
```

```
Unrated       2
```

```
Name: count, dtype: int64
```

```
Content Rating
```

```
Everyone      80.39
```

```
Teen          11.14
```

```
Mature 17+    4.60
```

```
Everyone 10+   3.82
```

```
Adults only 18+ 0.03
```

```
Unrated       0.02
```

```
Name: proportion, dtype: float64
```

```
== Installs (ordinal) ==
```

```
Modus: 1,000,000+
```

```
== Price dalam USD (rasio) ==
```

```
Mean : 1.0274
```

```
Median : 0.0000
```

```
Std : 15.9497
```

```
Hanya aplikasi membayar -> n = 800, mean = 13.9208
```

Bandingkan mean `Price_USD` pada seluruh data dengan mean pada aplikasi membayar saja. Perbedaannya besar, karena sekitar 92% aplikasi berharga nol. Ini contoh bagaimana **memilih subpopulasi yang tepat** lebih menentukan daripada memilih rumus.

7.5 Tugas Tahap 3 — Kamus Variabel (bobot penilaian terbesar)

Isi tabel berikut untuk **seluruh 13 kolom asli**. Ketik langsung di sel Markdown di bawah.

Ketentuan:

1. Kolom "Alasan penetapan skala" wajib diisi, minimal satu kalimat, dan tidak boleh sekadar mengulang nama skalanya.
2. Untuk setiap kolom yang tipe datanya berbeda arah dengan skalanya, beri tanda dan jelaskan perbedaannya.
3. Sebutkan kolom mana saja yang **tidak boleh** dihitung rata-ratanya, beserta alasannya.
4. Tetapkan satu kolom sebagai calon **variabel terikat** dan dua kolom sebagai calon **variabel bebas** untuk pertanyaan manajer produk pada bagian 4.

Kamus Variabel:

Nama kolom	Deskripsi	Tipe data pandas	Skala pengukuran
App	Nama aplikasi di Play Store	object	Nominal
Category	Kategori/pengelompokan aplikasi	object	Nominal
Rating	Skor penilaian rata-rata pengguna (skala 1–5)	float64	Ordinal (sering diasumsikan
Reviews	Total jumlah ulasan pengguna	object	Rasio
Size	Ukuran berkas unduhan aplikasi	object	Rasio
Installs	Estimasi jumlah pemasangan aplikasi	object	Ordinal
Type	Status pembayaran (Gratis atau Berbayar)	object	Nominal
Price	Harga aplikasi dalam dollar	object	Rasio
Content Rating	Klasifikasi kelompok usia target aplikasi	object	Ordinal
Genres	Sub-genre spesifik aplikasi	object	Nominal
Last Updated	Tanggal pembaruan terakhir aplikasi	object	Interval
Current Ver	Nomor versi rilis aplikasi saat ini	object	Nominal
Android Ver	Versi minimum sistem operasi Android	object	Ordinal

Kolom yang TIDAK BOLEH dihitung rata-ratanya:

- Installs (alasan: Datanya berskala ordinal berupa batas bawah pengelompokan rentang/kategori, bukan nilai pasti; menghitung rata-ratanya menghasilkan angka semu yang bias secara matematis)
- Category / Genres / Type / App (alasan: Berskala nominal murni berupa teks label kategori tanpa bobot numerik dan tanpa makna operasi aritmetika penjumlahan/pembagian)

- Current Ver / Android Ver (alasan: Berskala nominal/ordinal berupa string kode rilis kompatibilitas yang tidak memiliki selisih matematis yang konstan atau sah dirata-ratakan)

Calon variabel terikat: Rating / Installs / Jumlah Unduhan sebagai tolok ukur penerimaan/kesuksesan aplikasi).

Calon variabel bebas (dua kolom):

1. Category, untuk menguji kategori mana yang paling menjanjikan bagi calon pengembang).
2. Type / Price, untuk membandingkan apakah aplikasi berbayar mendapat penilaian lebih baik daripada yang gratis).

✓ TAHAP 4 — Populasi, Sampel, Parameter, Statistik

Menjawab Tujuan Pembelajaran nomor 4

8.1 Pertanyaan pokok: dataset ini populasi atau sampel?

Jawabannya bergantung pada populasi yang Anda klaim.

Populasi yang diklaim	Status dataset	
"10.841 aplikasi yang tercatat dalam berkas ini"	Populasi	Semua hitungan adalah param
"Seluruh aplikasi di Google Play Store pada Februari 2019"	Sampel	Semua hitungan adalah statisti
"Seluruh aplikasi Android hari ini"	Sampel yang buruk	Data berusia bertahun-tahun. f

Status sebuah dataset tidak melekat pada datanya, melainkan pada klaim yang Anda buat tentangnya.

8.2 Lambang parameter dan statistik

```

1 r = bersih['Rating'].dropna()
2
3 print('Banyak pengamatan (n)          : %d' % len(r))
4 print('Rata-rata sampel (x-bar)       : %.4f' % r.mean())
5 print('Simpangan baku sampel (s)      : %.4f' % r.std(ddof=1))
6 print()
7 print('Nilai mu dan sigma untuk seluruh Play Store: TIDAK DIKETAHUI')
8

```

```

Banyak pengamatan (n)          : 9366
Rata-rata sampel (x-bar)       : 4.1918
Simpangan baku sampel (s)      : 0.5152

```

Nilai mu dan sigma untuk seluruh Play Store: TIDAK DIKETAHUI

Catat baik-baik: `ddof=1` pada baris simpangan baku. Itulah pembeda antara rumus s (statistik, pembagi $n-1$) dan σ (parameter, pembagi n). Pandas memakai `ddof=1` sebagai bawaan justru karena data biasanya diperlakukan sebagai sampel. Alasan matematis di balik $n-1$ akan dibahas pada Pertemuan 11.

8.3 Membuktikan sendiri bahwa statistik berubah antar sampel

```
1 print('%-8s %-10s %-10s' % ('Sampel', 'n', 'x-bar'))
2 print('-' * 30)
3 for i in range(1, 11):
4     contoh = r.sample(n=100, random_state=i)
5     print('%-8d %-10d %-10.4f' % (i, len(contoh), contoh.mean()))
6
7 print()
8 print('Rata-rata seluruh data (acuan): %.4f' % r.mean())
9
```

Sampel	n	x-bar
1	100	4.1470
2	100	4.1820
3	100	4.2340
4	100	4.2690
5	100	4.1490
6	100	4.2600
7	100	4.2080
8	100	4.2530
9	100	4.2060
10	100	4.1940

Rata-rata seluruh data (acuan): 4.1918

Inilah inti seluruh statistika inferensial. Sepuluh sampel acak dari data yang sama menghasilkan sepuluh nilai $\bar{x}$ yang berbeda, dan tidak satu pun persis sama dengan nilai acuannya. Keragaman itu bukan kesalahan, melainkan sifat alami penarikan sampel. Mengukur besarnya keragaman itulah pekerjaan Pertemuan 11, dan penjelasan mengapa keragamannya berbentuk lonceng adalah Teorema Limit Pusat pada Pertemuan 7.

Lanjutkan dengan mengamati pengaruh ukuran sampel:

```
1 for n in [10, 30, 100, 500, 2000]:
2     hasil = [r.sample(n=n, random_state=k).mean() for k in range(200)]
3     print('n = %-5d | sebaran x-bar: min %.4f, maks %.4f, simpangan baku
4           % (n, min(hasil), max(hasil), np.std(hasil, ddof=1)))
5
```

n = 10		sebaran x-bar: min 3.6500, maks 4.5200, simpangan baku 0.1569
n = 30		sebaran x-bar: min 3.9133, maks 4.3933, simpangan baku 0.0873
n = 100		sebaran x-bar: min 4.0260, maks 4.3440, simpangan baku 0.0517
n = 500		sebaran x-bar: min 4.1328, maks 4.2696, simpangan baku 0.0255
n = 2000		sebaran x-bar: min 4.1643, maks 4.2186, simpangan baku 0.0104

Semakin besar n , semakin rapat sebaran $\bar{x}$ di sekitar nilai acuan. Tuliskan pengamatan Anda pada sel Markdown berikut.

Pengamatan Anda tentang pengaruh n terhadap sebaran $\bar{x}$:

Semakin besar ukuran sampel (n), variasi nilai rata-rata sampel ($\bar{x}$) menjadi semakin kecil, yang ditunjukkan oleh nilai simpangan baku (standard error) yang terus menurun dan rentang antara nilai minimum serta maksimum $\bar{x}$ yang semakin menyempit. Hal ini membuktikan prinsip Teorema Limit Pusat dan Law of Large Numbers, di mana penambahan ukuran sampel membuat estimasi $\bar{x}$ semakin rapat dan konsisten mendekati nilai parameter rata-rata populasi sebenarnya (μ). Sebaliknya, pada nilai n yang sangat kecil (seperti $n = 10$), nilai $\bar{x}$ sangat fluktuatif dan berisiko tinggi menghasilkan estimasi yang bias atau jauh dari nilai acuan.

✓ 8.4 Bias yang tidak bisa diperbaiki oleh besarnya n

```
1 print('Duplikat nama aplikasi :', bersih['App'].duplicated().sum())
2 print('Aplikasi unik          :', bersih['App'].nunique())
3 print()
4 print('Proporsi jenis aplikasi:')
5 print((bersih['Type'].value_counts(normalize=True) * 100).round(2))
6 print()
7 print('Rating kosong          : %d (%.2f%%)'
8       % (bersih['Rating'].isna().sum(),
9         100 * bersih['Rating'].isna().sum() / len(bersih)))
10
```

```
Duplikat nama aplikasi : 1181
Aplikasi unik          : 9659

Proporsi jenis aplikasi:
Type
Free    92.62
Paid    7.38
Name: proportion, dtype: float64

Rating kosong          : 1474 (13.60%)
```

Tiga temuan di atas masing-masing adalah ancaman terhadap generalisasi:

1. **Duplikat.** Satu aplikasi yang tercatat berkali-kali mendapat bobot lebih besar dari yang seharusnya. Apakah Anda membuang duplikatnya? Keputusan itu

wajib dilaporkan.

2. **Ketimpangan gratis dan berbayar.** Bila hampir seluruh data adalah aplikasi gratis, kesimpulan tentang aplikasi berbayar berdiri di atas sampel yang jauh lebih kecil daripada yang terlihat dari angka 10.841.
3. **Rating yang kosong.** Aplikasi tanpa rating besar kemungkinan adalah aplikasi baru atau tidak populer. Membuang begitu saja baris yang ratingnya kosong berarti diam-diam mengubah populasi yang Anda teliti menjadi "aplikasi yang cukup populer untuk mendapat rating". Ini contoh nyata *nonresponse bias*.

Tambahkan satu ancaman lagi yang melekat pada cara pengumpulannya: data ini hasil scraping satu kali. Aplikasi yang sudah dihapus sebelum Februari 2019 tidak pernah masuk, dan aplikasi yang rilis setelahnya juga tidak. Teknik pengambilannya bukan *simple random sampling*, melainkan lebih dekat ke *accidental sampling* atas apa pun yang berhasil diambil oleh program scraper.

Menambah data menjadi sepuluh kali lipat tidak menyembuhkan satu pun dari empat masalah di atas. Besarnya n hanya memperkecil galat acak. Galat sistematis harus diperbaiki di tahap perancangan pengambilan data.

✓ 8.5 Tugas Tahap 4

Tulis satu paragraf **minimal 150 kata** yang menjawab: **populasi apa yang sebenarnya diwakili dataset ini?** Paragraf wajib memuat:

1. Rumusan populasi yang menurut Anda paling jujur.
2. Minimal tiga sumber bias yang sudah Anda temukan lewat kode di atas.
3. Satu kalimat yang menyatakan kesimpulan seperti apa yang **tidak boleh** ditarik dari dataset ini.
4. Usulan perbaikan teknik pengambilan data seandainya Anda yang merancang ulang pengumpulannya.

Paragraf batas generalisasi (minimal 150 kata):

Rumusan populasi yang paling jujur untuk dataset ini bukanlah seluruh ekosistem Android secara universal, melainkan terbatas pada kumpulan aplikasi publik di Google Play Store yang berhasil diambil oleh skrip perayap (web scraper) pada jendela waktu Februari 2019. Generalisasi ke luar batasan tersebut sangat rentan bias karena tiga temuan kritis pada data: adanya 1.181 duplikasi nama aplikasi yang memberi bobot berlebih pada aplikasi tertentu, proporsi jenis aplikasi yang timpang ekstrem di mana sekitar 92% merupakan aplikasi gratis, serta keberadaan 1.474 baris missing value pada kolom Rating yang memicu nonresponse bias karena secara implisit

menyingkirkan aplikasi baru atau yang kurang populer. Oleh sebab itu, kesimpulan prediktif mengenai tren kesuksesan, adopsi pengguna, maupun penetapan harga aplikasi Android modern untuk kondisi ekosistem saat ini sama sekali tidak boleh ditarik dari dataset usang dan tidak seimbang ini. Seandainya pengumpulan data dirancang ulang, perbaikan wajib dilakukan dengan menerapkan teknik stratified random sampling berkala berbasis kategori dan tipe aplikasi secara berkala (longitudinal), merekam riwayat aplikasi yang sudah dihapus, serta menyaring data duplikat secara otomatis sebelum analisis dilakukan..

✓ Verifikasi Lingkungan Kerja

Lampirkan tangkapan layar keluaran sel berikut pada berkas PDF laporan, sesuai ketentuan LKM-01.

```
1 import numpy, pandas, scipy, matplotlib, seaborn, statsmodels
2 for m in (numpy, pandas, scipy, matplotlib, seaborn, statsmodels):
3     print('%-12s %s' % (m.__name__, m.__version__))
4
5 print()
6 print('Ukuran dataframe:', df.shape)
7 print('Kolom          : ', list(df.columns))
8
```

```
numpy      2.0.2
pandas     2.3.3
scipy      1.16.3
matplotlib 3.10.0
seaborn    0.13.2
statsmodels 0.14.6
```

```
Ukuran dataframe: (10841, 14)
```

```
Kolom      : ['App', 'Category', 'Rating', 'Reviews', 'Size', 'Installs']
```

9. Daftar Luaran yang Dikumpulkan

Sebelum mengunggah, pastikan seluruh butir berikut sudah lengkap:

- ☐ Notebook `TIF1501_P01_<NIM>_<Nama>.ipynb` dapat dijalankan ulang dari awal tanpa galat
- ☐ Ekspor PDF dari notebook
- ☐ Kamus variabel 13 kolom sudah terisi lengkap (bagian 7.5)
- ☐ Tiga pertanyaan penelitian sudah terisi beserta alasan penggolongannya (bagian 5.3)
- ☐ Tiga peran statistika beserta bukti keluaran kode (bagian 6.4)

- ☐ Paragraf batas generalisasi minimal 150 kata (bagian 8.5)
- ☐ Pengamatan tentang pengaruh n terhadap sebaran $\bar{x}$ sudah dituliskan (bagian 8.3)
- ☐ Tangkapan layar verifikasi lingkungan sudah dilampirkan
- ☐ Catatan Pengerjaan pada bagian bawah notebook sudah diisi

Tenggat: sebelum Pertemuan 2 dimulai, diunggah ke LMS.

Penamaan berkas: `TIF1501_P01_<NIM>_<Nama>.ipynb` dan
`TIF1501_P01_<NIM>_<Nama>.pdf`

10. Catatan Pengerjaan

Wajib diisi. Bila Anda memakai AI generatif untuk membantu, cantumkan bagian mana yang dibantu dan bagaimana Anda memverifikasinya. Anda harus mampu menjelaskan ulang setiap baris kode saat asistensi.

Isi catatan pengerjaan Anda di sini:

Praktikum ini saya kerjakan secara mandiri menggunakan Kaggle Notebook dengan mengikuti modul pembelajaran. Saya sempat menggunakan AI hanya sebagai teman diskusi untuk membantu mencari referensi dan mengecek pemahaman konsep, khususnya saat menentukan skala pengukuran variabel serta membedah batas populasi dan sampel. Seluruh sel kode sudah saya jalankan sendiri, dan hasilnya telah saya periksa.

11. Peta Praktik terhadap Tujuan Pembelajaran

Tujuan Pembelajaran P01	Dijawab pada	Bukti yang dinilai
1. Membedakan deskriptif, inferensial, dan probabilitas	Tahap 1	Tiga pertanyaan penelitian pada 5.3
2. Menunjukkan tiga peran statistika dalam Informatika	Tahap 2	Tiga peran + satu peran yang tidak dapat
3. Mengklasifikasikan skala pengukuran	Tahap 3	Kamus variabel 13 kolom pada 7.5
4. Membedakan populasi, sampel, parameter, statistik	Tahap 4	Paragraf batas generalisasi pada 8.5

12. Kaitan ke Pertemuan Berikutnya

Temuan pada praktik ini	Diselesaikan pada
Sebaran ukuran aplikasi menceng ke kanan, mean menyesatkan	Pertemuan 9 — ukuran pemusatan, IQR, dan pe
Ingin melihat pola rating antar kategori secara visual	Pertemuan 10 — visualisasi dan korelasi
$\bar{x}$ berubah-ubah antar sampel, seberapa jauh dari μ ?	Pertemuan 11 — distribusi sampling dan selang
Apakah aplikasi berbayar benar-benar dinilai lebih tinggi?	Pertemuan 14 — uji t dua sampel
Apakah jenis aplikasi berkaitan dengan kelompok content rating?	Pertemuan 14 — uji Chi-Square independensi
Bagaimana memprediksi kelas aplikasi dari fiturnya?	Pertemuan 3 dan 7 — Naïve Bayes dan Gaussiar

Simpan notebook ini. Beberapa pertanyaan di atas akan Anda jawab sendiri dengan data yang sama pada paruh kedua semester.

Referensi

- Gupta, L. (2019). *Google Play Store Apps* [Dataset]. Kaggle.
<https://www.kaggle.com/datasets/lava18/google-play-store-apps>
- Walpole, R. E., Myers, R. H., Myers, S. L., & Ye, K. (2017). *Probability and Statistics for Engineers and Scientists* (9th ed.). Pearson. Bab 1.
- Montgomery, D. C., & Runger, G. C. (2018). *Applied Statistics and Probability for Engineers* (7th ed.). Wiley. Bab 1 dan 6.
- Sugiyono. (2022). *Metode Penelitian Kuantitatif, Kualitatif, dan R&D* (2nd ed.). Alfabeta.

Praktik Pendamping Modul Pertemuan 1 — Statistika Dan Probabilitas (TIF1501)
Program Studi Teknik Informatika, Fakultas Teknologi Informasi, UNISKA MAB
Banjarmasin